

Automated Metabolite Identification System for Clinical Mass Spectrometry

結合 Spectral Entropy 演算

之自動化代謝物質譜資訊鑑定系統開發

—— 從非結構化質譜數據至臨床決策支援 ——

作者:莊哲岡 台北醫學大學 藥學院

指導老師:王三源副教授

目錄 [點擊即可連結](#)

研究動機.....	1
研究目的.....	1
研究方法.....	2
內容.....	3
資料清洗-正則表達式	3
核心演算.....	6
成果展示與資料視覺化.....	9
未來展望:高通量擴充性	10
Source Code & Documentation:	10

研究動機

隨精準醫療發展，透過質譜儀分析人體代謝質體 (Metabolomics) 已成為疾病診斷之關鍵。在代謝組學 (Metabolomics) 的臨床研究中，雖然目前科學界已普遍採用資料庫比對進行電腦判讀，但傳統的分析流程仍面臨以下挑戰：

1. 傳統演算模型之侷限：

過去常用的相似度演算法 (如 Dot Product 或 Cosine Similarity) 主要針對標準品設計，在處理如糞便、血液等具備複雜背景雜訊的臨床檢體時，往往難以有效區分微小但關鍵的質譜特徵，導致判定準確度受限。

2. 大數據處理效能：


面對數千筆規模的代謝體資料庫，若缺乏標準化的自動化 Pipeline，即便使用電腦判讀，在數據清洗與批次運算上仍存在效率瓶頸。

研究目的

本專案旨在透過 R 語言 建構一套高穩健性的自動化分析 Pipeline，以優化現有的質譜判定模式：

1. 導入進階演算模型：捨棄傳統 Dot Product，實作具備更高辨識度的 Spectral Entropy (譜圖熵) 相似度演算，提升在複雜背景下的化合物鑑定精準度。
2. 自動化 ETL 流程：利用正規表示式 (Regex) 建立標準化資料庫，實現多筆數據的高通量批次處理。
3. 強化科學可重複性：透過程式化定義核心運算參數，排除傳統判讀中的不確定性，確保研究產出符合臨床數據分析所需之一致性(consistency)與可重複性(Reproducibility)。

研究方法



相似度計算參考文獻

Li, Y., Kind, T., Folz, J. et al. Spectral entropy outperforms MS/MS dot product similarity for small-molecule compound identification. Nat Methods 18, 1524–1531 (2021). <https://doi.org/10.1038/s41592-021-01331-z>

內容

資料清洗-正則表達式

實作非結構化資料 (Unstructured Data) 之 ETL 流程：

利用正規表示式 (Regex) 精準定位關鍵特徵欄位，擷取代謝體特定資訊、將 m/z & intensity 資訊轉化為結構化矩陣 (Structured Matrix)，以利於進行高通量相似度演算。

原始文字檔

包含代謝物名稱、類別、質譜資訊

```
1 NAME: HMDB:HMDB04095-2361 5-Methoxytryptamine
2 PRECURSORMZ: 189.103
3 PRECURSORTYPE: M-H
4 FORMULA: C11H14N2O
5 Ontology:
6 INCHIKEY: JTEJPPKMYBDEMY-UHFFFAOYSA-N
7 INCHI: InChI=1S/C11H14N2O/c1-14-9-2-3-11-10(6-9)8(4-5-12)7-13-11/h2-3,6-7,13H,4-5,12H2,1H3
8 SMILES: COC1=CC2=C(NC=C2CCN)C=C1
9 RETENTIONTIME: CCS:
10 IONMODE: Negative
11 INSTRUMENTTYPE: Negative-Quattro_QQQ:10eV
12 INSTRUMENT: Quattro_QQQ:10eV
13 COLLISIONENERGY:
14 Comment: DB#=CCMSLIB00000425029; origin=GNPS
15 Num Peaks: 6
16 143.0 7.605
17 144.0 2.369
18 173.0 100.0
19 175.0 3.178
20 188.0 87.625
21 190.0 2.304
```

左欄為質譜的 m/z，右欄為 intensity



1. 字串、符號處理
2. 資料類型轉換

5-Methoxytryptamine

m/z	intensity
143.0	7.605
144.0	2.369
173.0	100.0
175.0	3.178
188.0	87.625
190.0	2.304

將圖譜資訊以矩陣方式儲存，一個物質儲存在一個矩陣

技術實作

○ ○ ○

```
sIndex_Name = grep("NAME:", tmp)
sIndex_PrecursorMZ = grep("PRECURSORMZ: ", tmp)
sIndex_PrecursorTYPE = grep("PRECURSORTYPE: ", tmp)
sIndex_NumPeaks = grep("Num Peaks: ", tmp)
```

- Feature Extraction: 利用 **正規表示式 (Regex)** 克服原始 .txt 格式異質性，自動化定位特徵資訊，取代人工檢索。

○ ○ ○

```
Name = gsub('.*:', "", x = tmp[sIndex_Name])
print(Name)
PrecursorMZ = gsub(pattern = ".*: ", "", x = tmp[sIndex_PrecursorMZ])
NumPeaks = as.numeric(gsub("Num Peaks: ", "", tmp[sIndex_NumPeaks]))
```

- 標準化清洗流程: 透過 gsub 排除格式雜訊並執行類型轉換 (Type Casting)

○ ○ ○

```
S = sIndex_NumPeaks + 1 #第幾行開始有Numpeaks數值
E = sIndex_NumPeaks + NumPeaks #Numpeaks數值在第幾行結束?
pIndex = cbind(S, E) #透過column合併資料

i = 1
Spec = list()
for(i in 1:nrow(pIndex))
{
  sIndex = pIndex[i, "S"] : pIndex[i, "E"]
  #pIndex為column資料pIndex[i, "S"]表示第i層的S

  #stringr::str_split(tmp[sIndex], "\t")
  mz = as.numeric(gsub("\t.*", "", tmp[sIndex]))
  #tmp = readLines(MSP_Path),
  intensity = as.numeric(gsub(".*\t", "", tmp[sIndex]))
  Spec[[i]] = cbind(mz, intensity)
}
```

- 動態邊界界定：利用 NumPeaks 動態決定每個物質質譜資訊的起始與結束位置
- 結構化轉換：將非結構化的文字檔，正式轉化為 R 語言可以運算的 List 與 Matrix 格式

核心演算

一、相似度計算參考文獻

Article | Published: 02 December 2021

Spectral entropy outperforms MS/MS dot product similarity for small-molecule compound identification

Yuan Yue Li, Tobias Kind, Jacob Folz, Arpana Vaniya, Sajjan Singh Mehta & Oliver Fiehn 

Nature Methods **18**, 1524–1531 (2021) | [Cite this article](#)

9158 Accesses | 55 Citations | 24 Altmetric | [Metrics](#)

本篇研究利用 **Spectral Entropy** 相似度演算。相較於傳統 Dot-Product，本方案在面對臨床檢體雜訊時具備更卓越的 **穩健性 (Robustness)**。對比圖譜資訊，找出具有相同結構的小分子物質，並對比 42 種傳統演算法，例如 dot-product similarity，發現其在面臨雜訊干擾時，具有更高的穩健性。。

二、數學意義

Spectral entropy 是利用香農熵 (Shannon entropy) 將**頻譜密度 (頻域功率分布)** 編碼成單一數值，用於衡量訊號的**頻譜複雜度**

三、用於圖譜時的計算方式

假設要計算圖譜 A 與圖譜 B 的 spectral entropy similarity

定義 m/z 為 M , intensity 為 I . 圖譜 A 為不同 m/z 峰值的集合:

$$(M_{A,1}, I_{A,1}), \dots, (M_{A,i}, I_{A,i}).$$

定義 m/z 為 M , intensity 為 I . 圖譜 B 為不同 m/z 峰值的集合:

$$(M_{B,1}, I_{B,1}), \dots, (M_{B,i}, I_{B,i}).$$


產生組合圖譜用於計算 spectral distance

$$I_{AB,i} = \frac{1}{2}I_{A,i} + \frac{1}{2}I_{B,i}$$

spectral entropy 的定義:

$$S = - \sum_i I_i \times \ln I_i$$

計算 entropy similarity 的原理如下圖(page 7)



(圖片來源: Li Y, Spectral entropy outperforms MS MS dot product similarity for small-molecule compound identification)

Entropy similarity 介於 0 到 1 之間，0 代表完全不相似，1 代表完全相同

技術實作

○ ○ ○

```
# 核心演算：跨樣本相似度批次比對
library(purrr)
library(msentropy)

# 透過 map 函式對接已結構化之 Spec 列表進行高通量運算
similarity_score <- map(seq_along(Spec), ~ {
  calculate_entropy_similarity(
    peaks_a = target_sample,      # 定義待測目標樣本
    peaks_b = Spec[[.x]],        # 動態對接資料庫中第 x 個代謝物
    ms2_tolerance_in_da = 0.01,  # 設定質譜儀容許誤差 (Da)
    ms2_tolerance_in_ppm = 10,   # 設定相對誤差範圍 (ppm)
    max_peak_num = 10           # 擷取前 10 強特徵峰進行精準判
  )
})
```

- 高通量相似度演算 (High-Throughput Scoring)

函數式編程應用：捨棄傳統迴圈，採用 `purrr::map` 實作批次運算，提升效率。

動態數據串接：直接串接前階段清洗完成之 **Nested List (Spec)**。

參數調控：調整特徵參數 (Tolerance & Peak Threshold)，確保在具有雜訊之檢體與有限解析度質譜儀等實驗環境下具備高鑑定穩健性。

成果展示與資料視覺化

利用 R 內建函式繪製質譜資訊比對圖，將相似度計算結果資料視覺化。



1. 輸入未知代謝體質譜資訊

	mz	intensity
1	108.889	15.431
2	113.407	53.522
3	114.285	100.000
4	114.536	47.916
5	136.499	22.350
6	136.876	17.753
7	154.447	11.029
8	155.451	32.825
9	155.577	24.099



計算 spectral entropy
similarity

與代謝物資料庫進行相似
度計算產生質譜比對圖



- 稱式質譜圖 (Head-to-Tail Plot)：上方（黑線）為未知檢體，下方（紅線）為資料庫標竿物質。
- 判定指標：顯示 Spectral Entropy Similarity Score。

Name	Type	Value
[[341]]	double [1]	0.8623917
[[828]]	double [1]	0.05843605
[[393]]	double [1]	1.071803

與物質 393similarity score 為何>1 ?

在 R 套件 msentropy 的實作中，calculate_entropy_similarity 預設採用了加權機制 (Weighted algorithm)。雖然參數中未顯式宣告，但套件會自動對 peaks 進行強度轉換。另外，我設定 max_peak_num = 10，系統只選取最強的前 10 個碎片進行比對。在這種高強度特徵集中的情況下，加權效應會更加明顯，這解釋了為何高匹配圖譜資訊的 Score 會出現略高於 1.0 的數值，可由此結果推論為知代謝體為 393 號代謝體

未來展望:高通量擴充性

系統具備擴充性：本 Pipeline 採用函數式編程架構，未來僅需將輸入端改為 List-map 結構，即可升級為高通量批次分析模式，支援同時處理數千筆未知檢體之自動化鑑定。

Source Code & Documentation:

可於 GitHub 獲取完整 Pipeline 實作細節，包含資料清洗 (ETL) 與 Spectral Entropy 演算模組。

<https://github.com/kang918/Metabolite-ID-Pipeline>

